



UNIVERSITÀ  
DEGLI STUDI  
FIRENZE

Scuola di Scienze Matematiche, Fisiche e Naturali  
Corso di Laurea in Informatica

Tesi di Laurea

UTILIZZO DI SOFT-BROWNIAN-OFFSET  
PER LA GENERAZIONE DI ATTACCHI AI  
FINI DELL'ADDESTRAMENTO DI  
RILEVATORI DI INTRUSIONI

APPLICATION OF  
SOFT-BROWNIAN-OFFSET TO GENERATE  
CYBER-ATTACKS TO TRAIN INTRUSION  
DETECTORS

GUGLIELMO BARTELLONI

Relatore: *Relatore*  
Correlatore: *Correlatore*

Anno Accademico 2022-2023



---

## INDICE

---

1	Introduzione	7
2	Fondamenti	9
2.1	Intrusion Detection System	9
2.1.1	Signature-Based Detection	10
2.1.2	Anomaly-based Detection	10
2.1.3	Stateful-Protocol-Analysis	12
2.2	Machine Learning per rilevamento di intrusioni	12
2.3	XGboost	15
2.3.1	Alberi di Decisione	15
2.4	Dataset	16
2.4.1	ADFA-NET	16
2.4.2	CIDDS-18	16
3	Soft Brownian Offset	17
3.1	Autoencoder	17
4	Generazione di attacchi usando Soft Brownian Offset	21
4.1	Metodologie	21
5	Risultati	25
5.1	Preparazione dei dati	25
5.2	Generazione dei pacchetti	26
5.3	Rappresentazione grafica dei dati	26
5.3.1	Generazione a partire dai pacchetti normali	27
5.3.2	Generazione a partire dai pacchetti attacco	27
5.4	Addestramento del modello	31
5.5	Calcolo delle metriche	31
6	Conclusioni	33



---

## ELENCO DELLE FIGURE

---

Figura 1	Schema che riassume i vari metodi di implementazione degli AIDS, da [1]. I modelli sono divisi nelle tre categorie descritte precedentemente, ma sono presenti anche i vari tipi di algoritmi utilizzati. 11
Figura 2	Il processo del Supervised Machine Learning, da [2] 13
Figura 3	L'immagine mostra un esempio di albero di decisione di Carl Kingsford e Steven L Salzberg [3] 15
Figura 4	Schema che rappresenta l'approccio utilizzato da SBO. Inizialmente i dati ID vengono usati per addestrare l'autoencoder e successivamente vengono generati i dati OOD tramite SBO. Questi poi vengono decodificati dall'AE per integrarsi nel dataset iniziale. Infine, viene addestrata una rete neurale, nel nostro caso invece, utilizzeremo XGBoost. 18
Figura 5	Schema che rappresenta il modello autoencoder. Da [20] 19
Figura 6	(Dataset ADFANET - Generazione da normali) In giallo i pacchetti di attacco, in viola i pacchetti generati ed in verde i pacchetti normali. Questi grafici sono stati prodotti a partire da una porzione di dati ristretta per permettere una migliore visualizzazione. 28
Figura 7	(Dataset ADFANET - Generazione da normali) Questa figura presenta i dati della figura 6 ingranditi per permettere una migliore visualizzazione. 28
Figura 8	(Dataset ADFANET - Generazione da normali) Sono stati utilizzati 75 000 pacchetti in totale. Anche in questo caso si nota i medesimi problemi delle figure 6 e 7. 29
Figura 9	(Dataset ADFANET - Generazione da normali) Versione ingrandita di 8. 29
Figura 10	(Dataset CICIDS - Generazione da normali) Si nota la maggiore complessità di questo dataset, ma si presentano gli stessi problemi di ADFANET. 30

#### 4 Elenco delle figure

- Figura 11 (Dataset CICIDS - Generazione da normali) Questa immagine contiene grafici con più di 62 000 pacchetti. Nel grafico in alto a sinistra si nota come i pacchetti generati siano sovrapposti a quelli normali. 30
- Figura 12 (Dataset CICIDS - Generazione da attacchi) Questa immagine contiene grafici con più di 62 000 pacchetti. Nel grafico in alto a sinistra si nota come i pacchetti generati siano sovrapposti a quelli di attacco. 31

*"If you put water into a cup, it becomes the cup. You put water into a bottle,  
it becomes the bottle. You put it in a teapot, it becomes the teapot. Now,  
water can flow or it can crash. Be water, my friend."  
— Bruce Lee*





---

## INTRODUZIONE

---

Un sistema di rilevamento di intrusioni, anche detto intrusion detection system (IDS), è un'applicazione o un dispositivo volta a monitorare continuamente la rete per identificare attività malevole.

In particolare un IDS controlla il traffico di rete oppure i log di sistema, alla ricerca di possibili anomalie che potrebbero indicare la presenza di attacchi.

Per migliorare il rilevamento delle intrusioni, nell'ultimo decennio, si è iniziato ad utilizzare algoritmi di Machine Learning e Deep Learning attingendo informazioni dai Big Data. [4]

Questo però ha portato a nuove problematiche, come ad esempio il fatto che i modelli di Machine Learning sono molto sensibili ai dati di addestramento.

Un dataset contenente pacchetti di rete sarà composto per la maggior parte da pacchetti "normali", cioè pacchetti di traffico abituale e, per la restante parte, da pacchetti di attacchi. I vari dataset sul traffico di rete presenti oggi però, non hanno una quantità sufficiente di attacchi per poter addestrare al meglio i modelli.

Un modello addestrato su un dataset con una percentuale di attacchi troppo bassa, non sarà in grado di rilevare bene gli attacchi [5].

Un metodo per sopperire a questa mancanza è quello di generare nuovi dati a partire da quelli già esistenti (Data Augmentation). I dati generati devono essere però sufficientemente differenti di modo da rappresentare meglio le anomalie che si hanno nella rete durante un attacco.

In questa tesi esploreremo un algoritmo di Data Augmentation chiamato Soft-Brownian-Offset (SBO) [6] e lo utilizzeremo per generare nuovi dati per addestrare un IDS.

In particolare Soft-Brownian-Offset permette di generare campioni così detti out-of-distribution (OOD), cioè campioni che non fanno parte della distribuzione dei dati di partenza. Questo è coerente col fatto che di solito i pacchetti di attacchi sono fuori dalla distribuzione dei pacchetti comuni.



---

## FONDAMENTI

---

### 2.1 INTRUSION DETECTION SYSTEM

Un intrusione può essere definita come un evento che compromette integrità, confidenzialità e la disponibilità di un sistema informatico [7].

Gli Intrusion Detection System (IDS) sono delle soluzioni hardware o software che, posti all'interno di una rete o di un sistema, rilevano eventuali intrusioni.

Questi strumenti sono essenziali per tenere al sicuro le persone da attacchi informatici [1].

[8] Le principali funzioni degli IDS sono:

- Monitorare ed analizzare sia le attività utente che di sistema
- Tracciare le violazioni delle policy utente
- Analizzare le configurazioni e le vulnerabilità del sistema
- Rilevare tipici attacchi di rete
- Analizzare di attività anomale

[9] Solitamente gli IDS vengono classificati in base al tipo di analisi che effettuano e come questi rilevano le minacce. Ne esistono di tre tipi principali:

- Signature-Based Detection (SD)
- Anomaly-based Detection (AD)
- Stateful Protocol Analysis (SPA)

### 2.1.1 *Signature-Based Detection*

Questo tipo di rilevamento utilizza la firma di un attacco per poterlo rilevare. Quindi conoscendo questa firma, gli IDS la comparano agli eventi catturati della rete. Dato che questi attacchi hanno bisogno di una conoscenza pregressa sono anche chiamati Knowledge-based.

### 2.1.2 *Anomaly-based Detection*

Gli Anomaly-based Intrusion Detection Systems (AIDS) sono stati introdotti per sopperire alle mancanze del Signature-Based Detection. Questo tipo di rilevamento utilizza un modello che rappresenta il normale comportamento della rete. Se viene rilevato un evento che non è coerente con il modello di riferimento, allora viene segnalata un'anomalia. Questo tipo di rilevamento è chiamato anche Behavior-Based.

Il principale vantaggio di questo tipo di IDS è la possibilità di rilevare gli attacchi zero-day [10], in quanto questi sistemi, non si basano sulla firma dei dati o su regole rigide. Tra gli altri vantaggi si ha che risulta essere difficile, per un eventuale criminale, capire quale sia il comportamento normale di un utente senza produrre un segnale da parte del sistema [1].

Gli AIDS possono essere classificati in base al metodo utilizzato per la loro implementazione:

- Basati sulla Statistica (Statistical-Based)
- Basati sulla Conoscenza (Knowledge-Based)
- Basati sull'apprendimento automatico (Machine Learning-Based)

Gli AIDS Statistical-Based dopo aver registrato i dati di una porzione di elementi, derivano il modello statistico di un utente nella rete.

I Knowledge-based invece, utilizzano regole predefinite per generare il modello di riferimento. Dall'altra parte troviamo gli AIDS Machine Learning-Based, che utilizzano un algoritmo di apprendimento automatico per generare il modello di riferimento.

La figura 1 mostra più in dettaglio questo tipo di classificazione e i metodi di implementazione associati.




Figura 1: Schema che riassume i vari metodi di implementazione degli AIDS, da [1]. I modelli sono divisi nelle tre categorie descritte precedentemente, ma sono presenti anche i vari tipi di algoritmi utilizzati.

### 2.1.3 *Stateful-Protocol-Analysis*

In questo caso gli IDS conoscono lo stato e le specifiche del protocollo utilizzato. Vengono quindi rilevati degli eventi che non rispettano gli standard del protocollo, generalmente quelli da specifica e.g. IEEE.

Potrebbe sembrare che gli AD e gli SPA siano simili, in realtà i primi, conoscono il comportamento di una specifica rete, mentre i secondi, conoscono solo gli standard dei protocolli.

## 2.2 MACHINE LEARNING PER RILEVAMENTO DI INTRUSIONI

Il Machine Learning (ML) è un sottoinsieme dell'intelligenza artificiale e permette ai sistemi di imparare dai dati e di migliorare le loro prestazioni nel tempo senza essere esplicitamente programmati. Nel caso degli Intrusion Detection Systems, gli algoritmi di ML permettono di rilevare in maniera precisa e rapida gli attacchi per grandi quantità di dati in poco tempo [11].

Solitamente questi algoritmi sono divisi in:

- Supervised
- Unsupervised

Inoltre gli algoritmi di ML possono essere usati per la classificazione o per la predizione.

Il processo di classificazione si compone di vari passi tra cui:

- Preprocessamento dei dati
- Definizione dei dati di test
- Scelta dell'algoritmo
- Impostazione dei parametri
- Addestramento del modello
- Test del modello

come mostrato in figura 2.

Il modello viene addestrato su un dataset con classi conosciute e cerca di trovare una relazione tra le caratteristiche dei dati (features) e le classi stesse. In particolare un classificatore mappa una funzione:

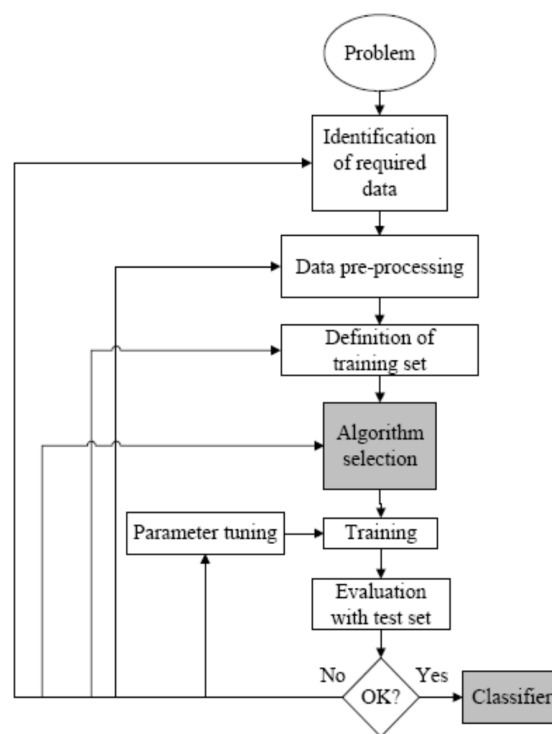


Figura 2: Il processo del Supervised Machine Learning, da [2]

$$f(x_1, \dots, x_S) \in \mathcal{C}$$

che assegna uno scalare facente parte di un insieme  $\mathcal{C}$  di elementi disgiunti (le classi), ad un insieme di  $S$  elementi vettoriali (le caratteristiche) [12].

Nella regressione invece, si cerca di approssimare la funzione:

$$f(x_1, \dots, x_S) = y$$

a partire dalle caratteristiche. La funzione  $f$  è approssimata utilizzando varie tecniche di interpolazione, estrapolazione, analisi di regressione e curve fitting [12].

Nel nostro caso utilizzeremo un algoritmo di classificazione.

### *Supervised Machine Learning*

Il Supervised Machine Learning utilizza un dataset con classi completamente etichettate cercando di trovare una relazione tra gli elementi del dataset e le classi di questi dati. I dataset utilizzati per l'addestramento, necessitano di essere catalogati precedentemente. Ci sono vari algoritmi di questo tipo e.g. Support Vector Machine (SVM), Naïve Bayes, Reti Neurali, Alberi di Decisione, Random Forest.

### *Unsupervised Machine Learning*

In questo caso, gli algoritmi di ML non hanno un dataset con classi etichettate. Questi algoritmi trovano delle relazioni tra i dati, cercando di raggrupparli in base a delle caratteristiche comuni.

L'unsupervised machine learning mostra però basse prestazioni per quanto riguarda il rilevamento quindi non possono essere utilizzati come principale strumento per gli IDS. Il motivo di questo scarso rendimento è dovuto al fatto che è molto probabile generare dei Falsi Positivi (vengono rilevati attacchi quando in realtà non ce ne sono) oppure generare dei Falsi Negativi (non vengono rilevati attacchi quando in realtà ce ne sono) questo va a degradare le performance generali del modello.

D'altra parte però questi modelli si sono dimostrati opinabilmente migliori per rilevare gli attacchi zero-day. [10].



## 2.3 XGBOOST

XGBoost (eXtreme Gradient Boosting) è un algoritmo di Machine Learning che utilizza alberi di decisione per la classificazione e la regressione.

Nel mondo reale è utilizzato anche la predizione dei click per le pubblicità [13] e come algoritmo per le competizioni su Kaggle [14].

Il suo punto di forza principale è la grande scalabilità in tutti gli scenari. XGBoost ha prestazioni superiori di dieci volte rispetto alle soluzioni esistenti. Inoltre riesce a sfruttare al meglio la potenza di calcolo della macchina su cui viene eseguito [14]. È stato scelto XGBoost come algoritmo in questa tesi per i motivi sopra citati.

### 2.3.1 Alberi di Decisione

Nella sua parte fondamentale XGBoost utilizza gli alberi di decisione.

Un albero di decisione è uno strumento relativamente semplice per classificare i dati dove vengono poste delle domande che riguardano le features. Ogni domanda è contenuta in un nodo dell'albero, ed ognuno di questi punta ad un figlio che rappresenta una possibile risposta. In questo modo le domande formano una gerarchia (Figura 3), codificata come un albero [3].

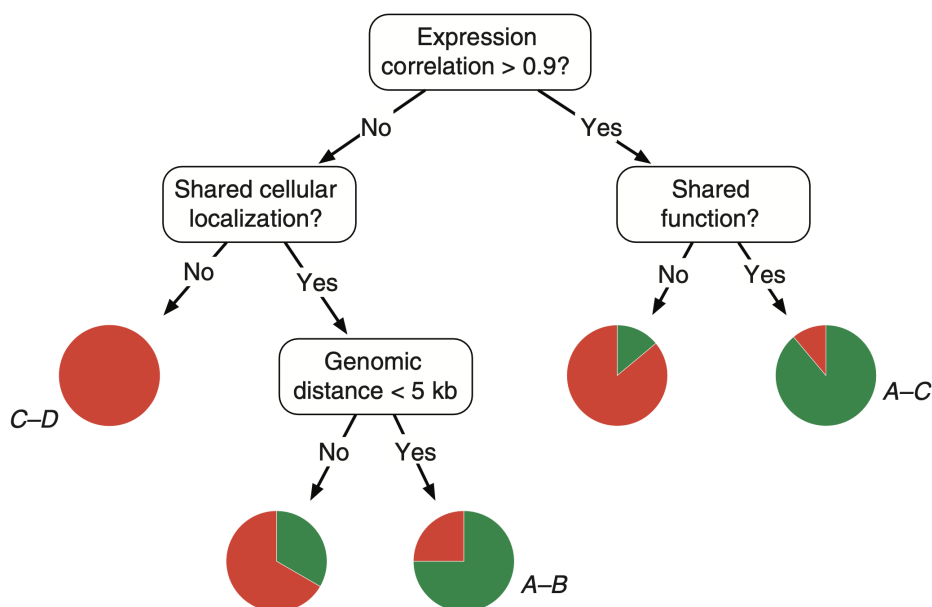


Figura 3: L'immagine mostra un esempio di albero di decisione di Carl Kingsford e Steven L Salzberg [3]

L'algoritmo più conosciuto che utilizza alberi di decisione è il C4.5 [15].

## 2.4 DATASET

I dataset sono un insieme di dati utilizzati per l'addestramento e il test dei modelli di ML. In questa tesi sono stati utilizzati tre dataset: ADFA-NET, CIDDS e CIC-IDS18.

### 2.4.1 ADFA-NET

ADFA è un dataset creato da un gruppo di ricerca dell'Università di New South Wales (Australia) nel 2013 e include dieci tipi di attacchi. Contiene in particolare attacchi di Brute Force, Java Based Meterpreter, Add new Superuser, Linux Meterpreter payload e attacchi alla C100 Webshell. [16]

Questo è il più semplice dataset su cui sono stati effettuati i test.

### 2.4.2 CIDDS-18

Solitamente i dataset non rappresentano al meglio la realtà, in quanto per motivi di privacy questi vengono offuscati e anonimizzati perdendo molta della diversificazione utile per l'addestramento di un modello. Per sopperire a queste mancanze è stato creato CIC-IDS cercando di mantenere il più possibile caratteristiche di uno scenario reale. Esso contiene una grande quantità di dati ricoprendo le principali tipologie di attacchi che si possono trovare in una rete, tra questi abbiamo DoS, DDoS, Brute Force, XSS, SQL Injection, Infiltrazione, Port scan e Botnet [16].

Questo risulta di gran lunga il più complesso dataset utilizzato in questa tesi contenendo più di settanta colonne e quasi duecentomila righe.

---

## SOFT BROWNIAN OFFSET

---

Soft Brownian Offset (SBO) è un algoritmo per la generazione di dati sintetici fuori dalla distribuzione (Out of Distribution OOD).

È stato sviluppato da [6] inizialmente per poter migliorare il rilevamento dei dati fuori dalla distribuzione, si pensi ad esempio nel caso dei cyber-physical systems (CPS) e.g. auto a guida autonoma, dove il rilevamento di eventi anomali è di vitale importanza [17].

Per questo scopo i dati generati necessitano di essere non troppo dissimili da quelli originali, perché altrimenti il modello potrebbe soffrire di "overconfidence" [18].

SBO si basa sul "Gaussian Hyperspheric Offset" che cerca di creare i dati OOD campionando attraverso una ipersfera attorno ai dati iniziali (In Distribution).

Partendo da quest'ultimo algoritmo, SBO permette di utilizzare qualsiasi punto del dataset e traslarlo in modo da avere una certa distanza minima dagli altri punti. I dati vengono processati da un autoencoder (AE) addestrato su un particolare dataset. La figura 4 mostra graficamente questo approccio.

### 3.1 AUTOENCODER

Un autoencoder è una particolare rete neurale che ha il compito di codificare un input e comprimerlo in una rappresentazione rilevante per poi decodificarlo e ricostruirlo nel modo più fedele possibile [19].

Il loro compito principale è quindi di imparare, in modo non supervisionato, una rappresentazione ridotta significativa dei dati.

Il problema può essere formalmente definito [20], come trovare le funzioni  $A:R^n \rightarrow R^p$  (encoder) e  $B:R^p \rightarrow R^n$  (decoder) in modo che:

$$\operatorname{argmin}_{A,B} E[\Delta(x, B(A(x)))]$$

dove  $E$  è la distribuzione di  $x$  che ci si aspetta, e  $\Delta$  è la funzione obbiettivo della ricostruzione, che misura la distanza tra l'output del decoder e l'input.

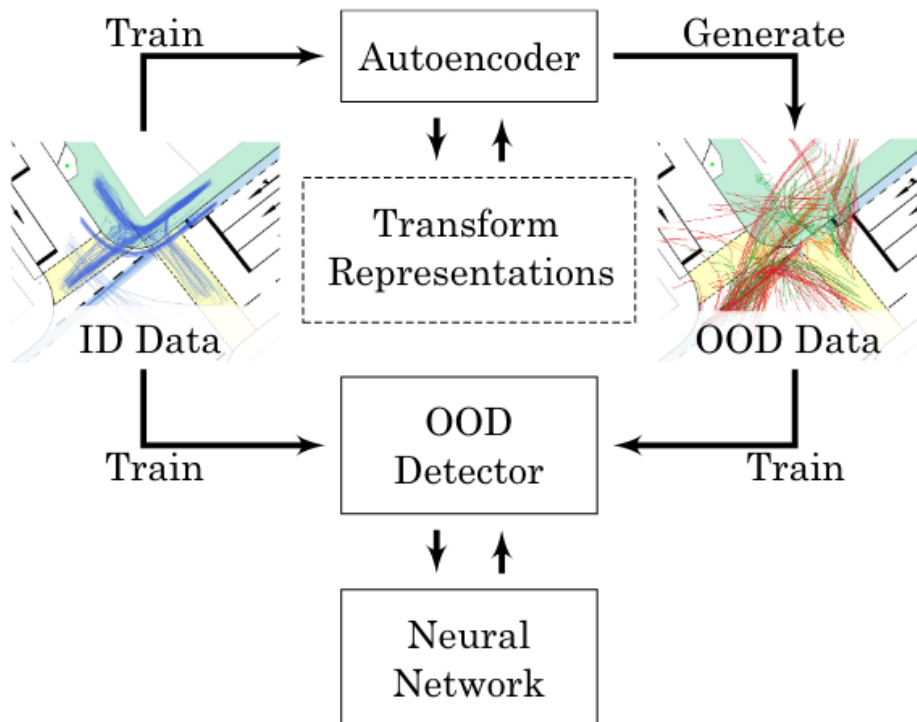


Figura 4: Schema che rappresenta l'approccio utilizzato da SBO. Inizialmente i dati ID vengono usati per addestrare l'autoencoder e successivamente vengono generati i dati OOD tramite SBO. Questi poi vengono decodificati dall'AE per integrarsi nel dataset iniziale. Infine, viene addestrata una rete neurale, nel nostro caso invece, utilizzeremo XGBoost.

La figura 5 mostra il processo del modello autoencoder.




Figura 5: Schema che rappresenta il modello autoencoder. Da [20]

L'approccio utilizzato per Soft Brownian Offset è quello di addestrare un autoencoder sul dataset di partenza, ridurre lo spazio di lavoro utilizzando l'encoder, generare i dati OOD ed infine ricostruire il dataset attraverso il decoder.



---

## GENERAZIONE DI ATTACCHI USANDO SOFT BROWNIAN OFFSET

---

La procedura adottata per questa tesi è la seguente:

- Preparazione dei dataset
- Generazione dei pacchetti Out of Distribution (OOD)
- Analisi dei dati ottenuti
- Addestramento del modello
- Valutazione del modello

Nel capitolo 5 verranno mostrati i risultati ottenuti.

### 4.1 METODOLOGIE

Ogni dataset è stato analizzato, per capire quali fossero i dati più significativi per l'addestramento del modello.

È stato necessario filtrare alcune colonne che contenevano valori non numerici come, nel caso di CIC-IDS, la colonna "Timestamp" che includeva la data e l'ora del pacchetto.

Inoltre le righe contenenti valori come "Inf" o "NaN" sono state modificate perché, se lasciate intatte, avrebbero causato errori durante la generazione dei dati out-of-distribution.

Entrambi i dataset hanno una colonna "Label" per indicare la classificazione del pacchetto, nello specifico, sono presenti le varie tipologie di attacchi e.g. "Bruteforce", "Dos", "PingScan", "PortScan". Dato che, nel nostro caso, non ci interessa sapere nello specifico la catalogazione del pacchetto, tutti gli attacchi, sono stati etichettati come "attack".

Dopo aver fatto queste operazione di preprocessing, si è passati alla generazione dei sample OOD.

Gen. \ Addestr.	N+OOD	N+AV+OOD	N+AV
$OOD_{CMP}$	$N+OOD_{CMP}$	$N+AV+OOD_{CMP}$	/
$OOD_N$	$N+OOD_N$	$N+AV+OOD_N$	/
$OOD_{AV}$	$N+OOD_{AV}$	$N+AV+OOD_{AV}$	/

Tabella 1: Combinazioni di generazione dei pacchetti e addestramento del modello, dove N = pacchetti normali, AV = pacchetti di attacchi veri, CMP = pacchetti normali + pacchetti di attacchi, OOD = pacchetti generati. Si trova poi AV OOD, N OOD, N+AV OOD, rispettivamente dati generati a partire da attacchi, dati generati a partire da pacchetti normali, dati generati a partire dal dataset completo

In particolare possiamo distinguere vari casi sia, per la generazione dei pacchetti sia, per l'addestramento del modello. Abbiamo infatti, tre tipologie di generazione:

- Generazione a partire da soli pacchetti normali.
- Generazione a partire da soli pacchetti di attacchi.
- Generazione a partire sia da pacchetti normali che da pacchetti di attacchi.

Per l'addestramento abbiamo:

- Addestramento del modello con i pacchetti normali e i pacchetti OOD.
- Addestramento del modello con i pacchetti normali, i pacchetti OOD e i pacchetti di attacchi.
- Addestramento del modello con i pacchetti normali e i pacchetti di attacchi.

Le combinazioni di addestramento e generazione danno luogo ad esiti diversi. La tabella 1 riassume le varie combinazioni.

Un metodo possibile che non è stato approfondito è quello di generare i pacchetti filtrando quelli troppo “vicini”, in termini di caratteristiche, ai pacchetti normali. Si ottiene così un dataset che ha la giusta quantità di dati out-of-distribution e potrebbe migliorare l'apprendimento di un modello.

La prima prova effettuata è stata quella di utilizzare Soft Brownian Offset a partire dal dataset completo senza distinzioni di classificazione di pacchetto,



per vedere se era possibile in questo modo, generare degli attacchi verosimili. Questa soluzione però genera dei pacchetti che sono troppo vicini, in termini di caratteristiche, a quelli normali perché i dataset hanno una quantità molto maggiore di dati normali rispetto a quelli di attacchi.

Un ulteriore metodo è quello di utilizzare solo i pacchetti normali per la generazione, questo rappresenta maggiormente uno scenario reale in quanto solitamente, i dati di attacco a disposizione sono pochi.

Evidenzieremo quindi le differenze che ci sono tra i vari approcci.

Per ogni metodo, la generazione tramite Soft Brownian Offset verrà eseguita quattro volte attraverso un ciclo “for” per testare i vari parametri, linearmente intervallati, di  $d_{\min}$  ( $d^-$ ) e softness ( $\sigma$ ). Il valore di  $d_{\text{off}}$  ( $d$ ) invece sarà calcolato come  $d_{\min} \cdot 0.7$  come da documentazione.

A seguito della generazione dei pacchetti, questi devono essere uniti al dataset iniziale e verranno etichettati come pacchetti di attacco.

Per avere un’idea più concreta della qualità della generazione, si procede con la visualizzazione grafica del nuovo dataset così creato, tramite l’algoritmo di riduzione di dimensionalità UMAP. Data la grande quantità di colonne che i dataset possiedono, la riduzione della dimensionalità dei dati è necessaria per permettere la loro rappresentazione su un piano in due dimensioni.

E’ stato scelto UMAP, rispetto alla sua alternativa TSNE, per la velocità di esecuzione [21].

Per i grafici è stata utilizzata la libreria Plotly per permettere l’esplorazione dei dati salvati in formato HTML.

Dunque si procede all’addestramento di XGBoost con gli iperparametri impostati sui valori di fabbrica.

Infine si valuta il modello utilizzando la metrica "Matthew’s correlation coefficient" (MCC) prendendo come dati di test il dataset iniziale (senza pacchetti OOD). Si è scelto di utilizzare questa metrica per il calcolo delle prestazioni del modello in quanto, rispetto all’accuracy test, MCC è efficace quando si ha un dataset sbilanciato [22] come nel nostro caso (abbiamo molti più pacchetti normali che pacchetti di attacchi).

Le metriche raccolte per ogni strategia di generazione sono state poi confrontate, per capire così quali sono gli effetti delle generazioni.



---

## RISULTATI

---

Di seguito verranno mostrati i dati più significativi prodotti attraverso del codice Python. Sono state utilizzate diverse librerie, tra cui:

- Pandas e Numpy, per la manipolazione dei dataset
- Plotly, per la visualizzazione dei dati
- UMAP, per la riduzione della dimensionalità dei dataset
- SBO, per la generazione dei dati fuori dalla distribuzione
- XGBoost, il modello addestrato
- Scikit-learn, per la valutazione del modello e per il preprocessing dei dati

Tutto il codice utilizzato si trova su Github [23] .

### 5.1 PREPARAZIONE DEI DATI

Come detto nel capitolo 4, i dati non possono essere utilizzati come sono ma hanno bisogno di un preprocessing. In particolare, sono stati eliminati i dati non numerici attraverso il metodo di Pandas "pandas.DataFrame.replace" come segue:

```
input_data.replace([np.inf, -np.inf], -1, inplace=True)
input_data.replace(np.nan, -1, inplace=True)
```

Si estrae poi la colonna label dal dataset, che dovrà essere utilizzata successivamente per il modello.

Si procede poi a rinominare le etichette dei vari attacchi in "attack":

```
attacks_packets_types = ['Bot', 'DDOS attack-HOIC', 'DDOS
                        attack-LOIC-UDP',
                        'DoS attacks-Hulk', 'DoS attacks-SlowHTTPTest',
                        'FTP-BruteForce',
                        'Infiltration', 'SSH-Bruteforce']
attacks_packets.replace(attacks_packets_types, 'attack', inplace=True)
```

Si estraggono poi i pacchetti normali e quelli di attacco:

```
normal_packets =input_data[input_data['label'] == "normal"]
attack_packets =input_data[input_data['label'] != "normal"]
```

## 5.2 GENERAZIONE DEI PACCHETTI

Si è generato i nuovi pacchetti attraverso la libreria Python SBO fornita da [6]. Il metodo "soft\_brownian\_offset" della libreria richiede:

- i dati da cui generare i nuovi pacchetti
- $d_{\min}$  ( $d^-$ )
- $d_{\text{off}}$  ( $d$ )
- softness ( $\sigma$ )
- numero di pacchetti da generare

```
data_ood =soft_brownian_offset(data_i, d_min_, d_off_,
                              softness=softness_,
                              n_samples=n_ood_samples)
```

## 5.3 RAPPRESENTAZIONE GRAFICA DEI DATI

In questa sezione esploreremo i dati generati da Soft Brownian Offset graficamente utilizzando la libreria UMAP [21] per ridurre la dimensionalità dei dati. .

I test sono stati eseguiti con i seguenti parametri:

```
umap_2d =UMAP(n_components=2, init='random', random_state=0,
              n_neighbors=70, min_dist=.8)
```

che risulta avere il giusto compromesso tra velocità e accuratezza.

Tramite la rappresentazione grafica dei dati è possibile notare in maniera chiara se i pacchetti generati sono più simili a quelli di attacco oppure a quelli normali. L'obiettivo è quello di generare dati che siano graficamente vicini ai pacchetti di attacco ma lontani da quelli normali, questo infatti si traduce, come vedremo nelle sezioni successive, in un addestramento del modello migliore. Le tecniche di generazioni più efficaci quindi, saranno quelle che riescono a generare pacchetti non troppo distanti da quelli di attacco già presenti nel dataset.

I dati inoltre sono stati generati attraverso varie impostazioni di SBO manipolando i parametri  $d^-$ ,  $d$  e  $\sigma$ .

Analizziamo quindi i due approcci citati nel capitolo 4 ossia la generazione dei dati partendo da solo pacchetti normali e la generazione dei dati partendo da solo pacchetti di attacco.

#### 5.3.1 *Generazione a partire dai pacchetti normali*

Questo metodo di generazione dei pacchetti, in uno scenario reale, è quello che potrebbe essere utilizzato maggiormente, in quanto solitamente non si hanno a disposizione tanti dati su attacchi informatici all'interno della propria rete, ma solo dati di traffico comune. In figura 6 si nota però, come questo metodo non sia molto efficace infatti, ci sono delle evidenti sovrapposizioni tra pacchetti normali e pacchetti generati mentre, in corrispondenza degli attacchi, questo non accade. In figura 8 troviamo un esempio di generazione di 25 000 pacchetti OOD e anche in questo caso, non ci sono miglioramenti. Le figure successive 10 e 11 sono invece i test eseguiti su CICIDS che ottengono i medesimi risultati.

E' evidente che i pacchetti generati, siano troppo simili ai pacchetti normali e troppo dissimili da quelli di attacco. Questa valutazione qualitativa potrebbe già darci un'idea sulla qualità di addestramento del modello.

#### 5.3.2 *Generazione a partire dai pacchetti attacco*

Questa è la modalità opposta rispetto a quella precedentemente citata, dove si generano i dati sintetici a partire dai pacchetti di attacco. Come vediamo in figura 12, in questo caso i pacchetti OOD, sono separati dai dati normali ma vicini a quelli di attacco. Questa, osservando i grafici, sembra essere una buona soluzione di generazione, nelle sezioni successive vedremo però che anche questo metodo non è efficace per migliorare il rilevamento da parte



Figura 6: (Dataset ADFANET - Generazione da normali) In giallo i pacchetti di attacco, in viola i pacchetti generati ed in verde i pacchetti normali. Questi grafici sono stati prodotti a partire da una porzione di dati ristretta per permettere una migliore visualizzazione.



Figura 7: (Dataset ADFANET - Generazione da normali) Questa figura presenta i dati della figura 6 ingranditi per permettere una migliore visualizzazione.

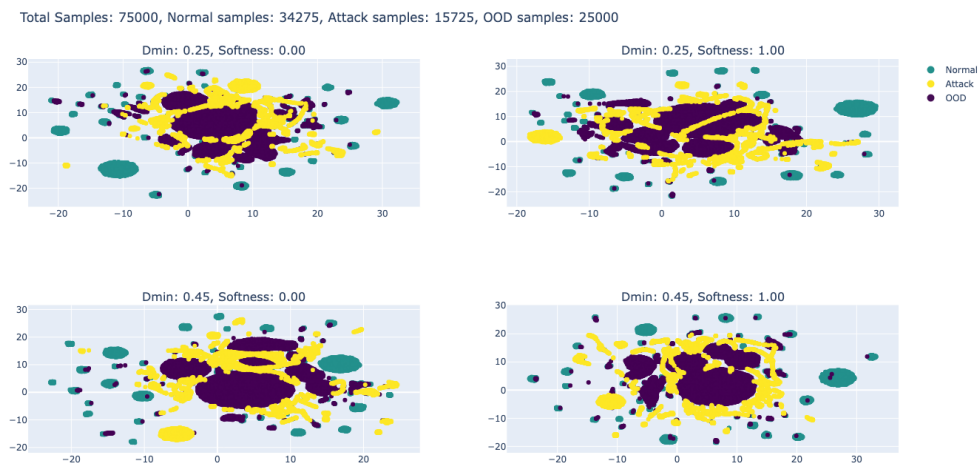


Figura 8: (Dataset ADFANET - Generazione da normali) Sono stati utilizzati 75 000 pacchetti in totale. Anche in questo caso si nota i medesimi problemi delle figure 6 e 7.

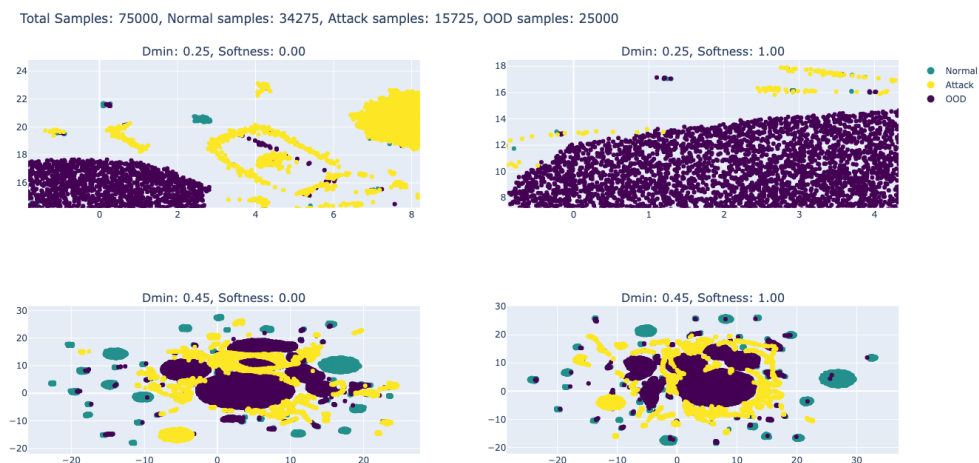


Figura 9: (Dataset ADFANET - Generazione da normali) Versione ingrandita di 8.

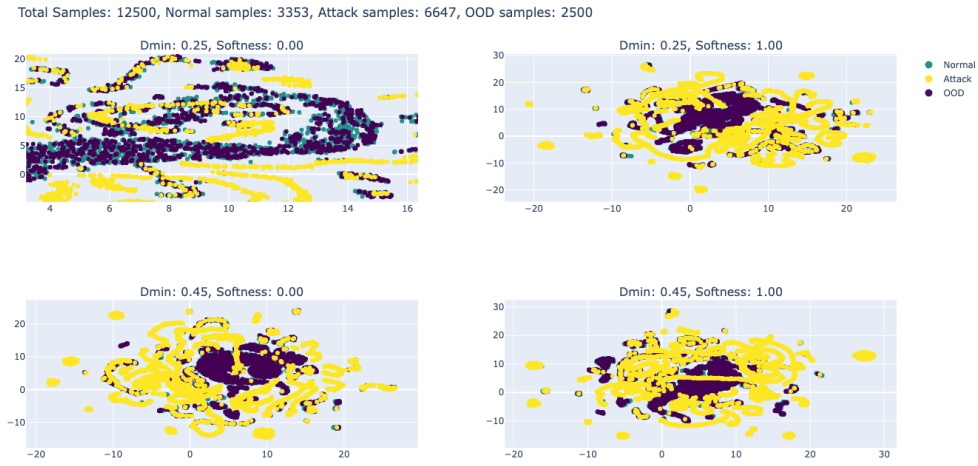


Figura 10: (Dataset CICIDS - Generazione da normali) Si nota la maggiore complessità di questo dataset, ma si presentano gli stessi problemi di ADFANET.

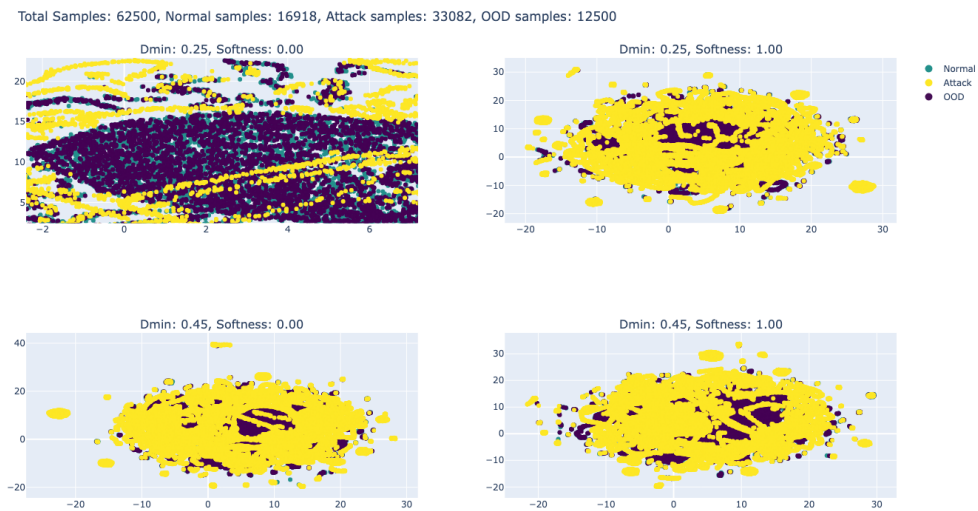


Figura 11: (Dataset CICIDS - Generazione da normali) Questa immagine contiene grafici con più di 62 000 pacchetti. Nel grafico in alto a sinistra si nota come i pacchetti generati siano sovrapposti a quelli normali.



del modello.



Figura 12: (Dataset CICIDS - Generazione da attacchi) Questa immagine contiene grafici con più di 62 000 pacchetti. Nel grafico in alto a sinistra si nota come i pacchetti generati siano sovrapposti a quelli di attacco.

## 5.4 ADDESTRAMENTO DEL MODELLO

## 5.5 CALCOLO DELLE METRICHE



---

## CONCLUSIONI

---



---

## BIBLIOGRAFIA

---

- [1] A. Khraisat, I. Gondal, P. Vamplew, and J. Kamruzzaman, “Survey of intrusion detection systems: Techniques, datasets and challenges,” *Cybersecurity*, vol. 2, p. 20, July 2019. (Citato nelle pagine 3, 9, 10, and 11.)
- [2] Babcock University, O. F.Y, A. J.E.T, A. O, H. J. O, O. O, and A. J, “Supervised Machine Learning Algorithms: Classification and Comparison,” *International Journal of Computer Trends and Technology*, vol. 48, pp. 128–138, June 2017. (Citato nelle pagine 3 and 13.)
- [3] C. Kingsford and S. L. Salzberg, “What are decision trees?,” *Nature Biotechnology*, vol. 26, pp. 1011–1013, Sept. 2008. (Citato nelle pagine 3 and 15.)
- [4] Z. Ahmad, A. Shahid Khan, C. Wai Shiang, J. Abdullah, and F. Ahmad, “Network intrusion detection system: A systematic study of machine learning and deep learning approaches,” *Transactions on Emerging Telecommunications Technologies*, vol. 32, Jan. 2021. (Citato a pagina 7.)
- [5] S. S. Gopalan, D. Ravikumar, D. Linekar, A. Raza, and M. Hasib, “Balancing Approaches towards ML for IDS: A Survey for the CSE-CIC IDS Dataset,” in *2020 International Conference on Communications, Signal Processing, and Their Applications (ICCSPA)*, (Sharjah, United Arab Emirates), pp. 1–6, IEEE, Mar. 2021. (Citato a pagina 7.)
- [6] F. Moller, D. Botache, D. Huseljic, F. Heidecker, M. Bieshaar, and B. Sick, “Out-of-distribution Detection and Generation using Soft Brownian Offset Sampling and Autoencoders,” in *2021 IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops (CVPRW)*, (Nashville, TN, USA), pp. 46–55, IEEE, June 2021. (Citato nelle pagine 7, 17, and 26.)
- [7] E. Biermann, E. Cloete, and L. Venter, “A comparison of Intrusion Detection systems,” *Computers & Security*, vol. 20, pp. 676–683, Dec. 2001. (Citato a pagina 9.)
- [8] A. S. Ashoor and S. Gore, “Importance of Intrusion Detection System,” vol. 2, no. 1, 2010. (Citato a pagina 9.)

- [9] H.-J. Liao, C.-H. Richard Lin, Y.-C. Lin, and K.-Y. Tung, “Intrusion detection system: A comprehensive review,” *Journal of Network and Computer Applications*, vol. 36, pp. 16–24, Jan. 2013. (Citato a pagina 9.)
- [10] T. Zoppi, A. Ceccarelli, and A. Bondavalli, “Unsupervised Algorithms to Detect Zero-Day Attacks: Strategy and Application,” *IEEE Access*, vol. 9, pp. 90603–90615, 2021. (Citato nelle pagine 10 and 14.)
- [11] T. Saranya, S. Sridevi, C. Deisy, T. D. Chung, and M. Khan, “Performance Analysis of Machine Learning Algorithms in Intrusion Detection System: A Review,” *Procedia Computer Science*, vol. 171, pp. 1251–1260, 2020. (Citato a pagina 12.)
- [12] F. Hoffmann, T. Bertram, R. Mikut, M. Reischl, and O. Nelles, “Benchmarking in classification and regression,” *WIREs Data Mining and Knowledge Discovery*, vol. 9, Sept. 2019. (Citato a pagina 14.)
- [13] X. He, J. Pan, O. Jin, T. Xu, B. Liu, T. Xu, Y. Shi, A. Atallah, R. Herbrich, S. Bowers, and J. Q. Candela, “Practical Lessons from Predicting Clicks on Ads at Facebook,” in *Proceedings of the Eighth International Workshop on Data Mining for Online Advertising*, (New York NY USA), pp. 1–9, ACM, Aug. 2014. (Citato a pagina 15.)
- [14] T. Chen and C. Guestrin, “XGBoost: A Scalable Tree Boosting System,” in *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, (San Francisco California USA), pp. 785–794, ACM, Aug. 2016. (Citato a pagina 15.)
- [15] S. L. Salzberg, “C4.5: Programs for Machine Learning by J. Ross Quinlan. Morgan Kaufmann Publishers, Inc., 1993,” *Machine Learning*, vol. 16, pp. 235–240, Sept. 1994. (Citato a pagina 16.)
- [16] I. Sharafaldin, A. Habibi Lashkari, and A. A. Ghorbani, “Toward Generating a New Intrusion Detection Dataset and Intrusion Traffic Characterization:,” in *Proceedings of the 4th International Conference on Information Systems Security and Privacy*, (Funchal, Madeira, Portugal), pp. 108–116, SCITEPRESS - Science and Technology Publications, 2018. (Citato a pagina 16.)
- [17] M. Yuhas, Y. Feng, D. J. X. Ng, Z. Rahiminasab, and A. Easwaran, “Embedded out-of-distribution detection on an autonomous robot platform,” in *Proceedings of the Workshop on Design Automation for CPS and IoT*, (Nashville Tennessee), pp. 13–18, ACM, May 2021. (Citato a pagina 17.)

- [18] D. Amodei, C. Olah, J. Steinhardt, P. Christiano, J. Schulman, and D. Mané, “Concrete Problems in AI Safety,” July 2016. Comment: 29 pages. (Citato a pagina 17.)
- [19] D. Bank, N. Koenigstein, and R. Giryes, “Autoencoders,” Apr. 2021. Comment: Book chapter. (Citato a pagina 17.)
- [20] P. Baldi, “Autoencoders, Unsupervised Learning, and Deep Architectures,” (Citato nelle pagine 3, 17, and 19.)
- [21] L. McInnes, J. Healy, and J. Melville, “UMAP: Uniform Manifold Approximation and Projection for Dimension Reduction,” Sept. 2020. Comment: Reference implementation available at <http://github.com/lmcinnes/umap>. (Citato nelle pagine 23 and 26.)
- [22] D. Chicco and G. Jurman, “The advantages of the Matthews correlation coefficient (MCC) over F1 score and accuracy in binary classification evaluation,” *BMC Genomics*, vol. 21, p. 6, Dec. 2020. (Citato a pagina 23.)
- [23] G. Bartelloni, “APPLICATION OF SOFT-BROWNIAN-OFFSET TO GENERATE CYBER-ATTACKS TO TRAIN INTRUSION DETECTORS,” Apr. 2023. (Citato a pagina 25.)